

Predykcja Niewypłacalności Przedsiębiorstw

Maciej Andrzejewski

Krzysztof Osiński




Cel i Zastosowanie Modeli PD



Główny Cel

Precyzyjna predykcja prawdopodobieństwa niewypłacalności (PD) dla przedsiębiorstw.




Automatyzacja Decyzji

Wsparcie w automatyzacji decyzji kredytowych dla przedsiębiorstw, usprawniając procesy.



Wyznaczanie Limitów

Definiowanie limitów kredytowych opartych na precyzyjnych klasach ratingowych.



Kalkulacja Rezerw

Precyzyjna kalkulacja rezerw i wymogów kapitałowych zgodnie z regulacjami.

Użytkownicy: Analitycy ryzyka, Komitety Kredytowe, zarządy instytucji finansowych.

Dane i Ich Przygotowanie

Źródło Danych: Wewnętrzne dane historyczne instytucji finansowej oraz dane rejestrowe (PKD, forma własności).

Wolumen: 3000 obserwacji (firm).

Zmienna Celu: default (1 = upadłość/niewypłacalność), kluczowa dla określenia ryzyka.

Niezbalansowanie: Default Rate wynosił około 12.97%.

Podział Danych dla Stabilności Modelu

- **Treningowy:** Do estymacji parametrów i tuningu hiperparametrów.
- **Kalibracyjny:** Kalibracja modeli do średniej PD na poziomie 4%.
- **Testowy:** Ocena skuteczności modeli i analiza interpretowalności.
- **Walidacyjny:** Ostateczna ocena stabilności metryk modeli na nowych danych.





Wyzwania i Rozwiązania w Przetwarzaniu Danych

Braki Danych

Dane finansowe są często niekompletne, ale usuwanie wierszy prowadzi do utraty cennych informacji. Łączny odsetek braków wyniósł 3.16%, z krytycznymi zmiennymi (np. RP_przepływy_operacyjne) usuniętymi z analizy.

Imputacja

Iterative Imputer (MICE) został użyty do uzupełnienia brakujących danych.


Transformacje

Zastosowano logarytmizację zmiennych skośnych, Weight of Evidence (WoE) dla kategoriycznych oraz winsoryzację (3-97 percentyl).

Analiza Mocy Predykcyjnej i Separowalność Klas


Information Value (IV)

Analiza IV pozwoliła na ranking cech pod kątem ich zdolności do separacji klas "Good" i "Bad", identyfikując zmienne z wysokim potencjałem predykcyjnym.




Redukcja Wymiarowości (PCA & t-SNE)

Wizualizacja 2D pokazała brak wyraźnej separacji między klasami niewypłacalności (1) i braku niewypłacalności (0), co sugeruje złożoną strukturę danych. Pierwsze dwa komponenty wyjaśniają tylko około 20% wariancji.



Złożone zależności w danych wymagają zastosowania modeli nieliniowych, takich jak XGBoost, aby w pełni wykorzystać ich potencjał predykcyjny.



Zaawansowana Selekcja Cech

W celu redukcji wymiarowości i eliminacji szumu, wdrożono hybrydowy mechanizm selekcji cech, łączący metody filtrowe, wbudowane i wrapperowe.

01

Filtry Wstępne

Usunięcie zmiennych o zerowej wariancji oraz silnie skorelowanych ($r > 0.7$).

02

Ranking Metodami Wiodącymi

Wybrano 30 najlepszych cech dla korelacji Pearsona, Mutual Information, RFE (Regresja Logistyczna) i Feature Importance (Random Forest).

03

Konsensus (Agregacja)

Ostateczny zbiór cech stanowi sumę mnogościową wyników powyższych metod, minimalizując ryzyko odrzucenia istotnych zmiennych.


04

Wynik

Z początkowej puli zmiennych wyselekcjonowano 93 zmienne.


Dwa Modele, Jedna Misja

Model Benchmarkowy (Interpretowalny)



Oparty na Regresji Logistycznej. Priorytetem jest pełna transparentność decyzji oraz zgodność z rygorystycznymi wytycznymi regulatorów (KNF, EBA) dotyczącymi zarządzania ryzykiem modelu.

Model Challenger (Black-Box)



Wykorzystujący algorytmy boostingowe (XGBoost) w celu maksymalizacji zdolności dyskryminacyjnej i wychwycenia nieliniowych zależności, które uykają modelom tradycyjnym.

Kalibracja Probabilistyczna i Jej Wyniki

Celem kalibracji było przekształcenie surowych wyników modeli w rzetelne prawdopodobieństwo niewypłacalności (PD), spełniające wymóg tendencji centralnej portfela na poziomie 4%.

Metodyka Kalibracji Hybrydowej



Korekta Kształtu

Platt Scaling (CalibratedClassifierCV) dopasował funkcję sigmoidalną.



Target Shifting

Analityczne przesunięcie interceptu, aby średnie PD wynosiło 4%.

Wyniki Kalibracji (Post-Calibration)

	ECE - przed kalibracją	Brier Score - przed kalibracją	ECE - po kalibracji	Brier Score - po kalibracji
Regresja Logistyczna	0.3315	0.2108	0.0914	0.1145
XGBoost	0.3598	0.2382	0.0901	0.1144

Zastosowana metoda kalibracji radykalnie poprawiła jakość predykcji, znacząco redukując błąd kalibracji.

Mapowanie PD na Klasy Ratingowe

Transformacja skalibrowanego prawdopodobieństwa niewypłacalności (PD) na dyskretną skalę ratingową (Master Scale) dla łatwiejszego raportowania i ustalania limitów kredytowych.

Definicja Progów Ratingowych (Algorytm K-Means)

Regresja Logistyczna

AAA	Znikome	0.00%	1.70%
AA	Bardzo niskie	1.70%	2.95%
A	Niskie	2.95%	4.37%
BBB	Umiarkowane	4.37%	6.17%
BB	Podwyższone	6.17%	8.25%
B	Wysokie	8.25%	10.98%
CCC	Bardzo wysokie	10.98%	21.49%
CC	Ekstremalne	21.49%	34.81%
C	Niewypłacalność	34.81%	100.00%

XGBoost


AAA	Znikome	0.00%	1.37%
AA	Bardzo niskie	1.37%	2.61%
A	Niskie	2.61%	4.04%
BBB	Umiarkowane	4.04%	5.41%
BB	Podwyższone	5.41%	7.11%
B	Wysokie	7.11%	9.31%
CCC	Bardzo wysokie	9.31%	10.94%
CC	Ekstremalne	10.94%	12.76%
C	Niewypłacalność	12.76%	100.00%

Model XGBoost jest bardziej restrykcyjny, szybciej degradując ratingi i klasyfikując firmy jako toksyczne, co minimalizuje potencjalne straty.


Analiza Dystrybucji Ryzyka: Profile PD Modeli

Poniżej przedstawiono rozkłady prawdopodobieństwa niewypłacalności (PD) dla obu modeli, uwzględniające uśrednione PD na poziomie 4% jako punkt odniesienia dla kalibracji.

Regresja Logistyczna: Rozkład PD



XGBoost: Rozkład PD



Interpretowalność Modeli i Progi Decyzyjne

Zgodnie z wymogami regulacyjnymi oraz potrzebą zrozumienia mechanizmów decyzyjnych, przeprowadzono pogłębioną analizę wyjaśnialności (eXplainable AI) dla obu modeli.

Metody Wyjaśnialności

Wykorzystano metody model-agnostic, w szczególności wartości **SHAP (SHapley Additive exPlanations)** oraz analizę zależności cząstkowych (**PDP/ICE**).

Fokus na Kluczowe Predyktory

Ze względu na dużą liczbę zmiennych, analiza koncentrowała się na **najważniejszych predyktorach** oraz tendencjach w danych, które mają decydujący wpływ na przewidywania modeli.

Przed przystąpieniem do interpretacji, wyznaczono optymalne progi decyzyjne, maksymalizujące miarę $F\beta$ (gdzie $\beta = 1$, kładąc równy nacisk na precyzję i czułość).

Regresja Logistyczna

Optymalny próg operacyjny dla modelu skalibrowanego: **6.40%**

XGBoost

Optymalny próg operacyjny dla modelu skalibrowanego: **5.97%**

Oznacza to, że każda firma z prawdopodobieństwem defaultu powyżej wyznaczonego progu jest klasyfikowana jako ryzykowna.

Kluczowe Cechy i Ich Wpływ na Predykcję


Zrozumienie, które zmienne mają największy wpływ na przewidywane prawdopodobieństwo niewypłacalności (PD), jest kluczowe dla interpretowalności i zaufania do modelu.

Regresja Logistyczna: Współczynniki

	Zmienna	β	OR	$ \beta $
0	numeric_pipeline_log_wsk_zadluzenia	0.0771	1.0801	0.0771
1	numeric_pipeline_log_Kapital_zapasowy	0.0562	1.0578	0.0562
2	numeric_pipeline_wsk_ogolnego_zadluzenia_pozyczki_squared	0.0439	1.0448	0.0439
3	numeric_pipeline_log_wsk_koszty_przychody	0.0429	1.0438	0.0429
4	numeric_pipeline_log_wsk_pokrycia_odsetek_zyskiem	0.0413	1.0422	0.0413
5	numeric_pipeline_wsk_zadluzenia_pozyczki_dlugie_sqrt	0.0395	1.0403	0.0395
6	numeric_pipeline_log_wsk_efekt_dzwigni_fin_1	0.0389	1.0396	0.0389
7	numeric_pipeline_log_pozostale_przychody_oper	0.0372	1.0379	0.0372
8	numeric_pipeline_log_Naleznosci_dostaw_uslug_12m_powiazane	0.0370	1.0377	0.0370
9	numeric_pipeline_log_wsk_ebitda_koszty_odsetkowe_3	0.0351	1.0358	0.0351
10	numeric_pipeline_log_wsk_rotacja_rz_aktywow_trwalych	0.0346	1.0352	0.0346

Współczynniki wskazują na kierunek i siłę wpływu każdej cechy na logarytm szansy niewypłacalności, zapewniając transparentność liniowych zależności.

XGBoost: Wartości SHAP



Wartości SHAP (SHapley Additive exPlanations) ujawniają indywidualny wkład każdej cechy w przewidywania modelu, uwzględniając złożone, nieliniowe interakcje.

Kluczowe Cechy i Wnioski Biznesowe

Mimo różnic w architekturze, oba modele zgodnie wskazały grupę fundamentalnych wskaźników finansowych determinujących ryzyko:



Kapitał Zapasowy (log)

Wysoki poziom kapitału zapasowego jest najsilniejszym stabilizatorem (obniża ryzyko).



Wskaźnik Zadłużenia Ogólnego (log)

Wzrost zadłużenia wprost proporcjonalnie zwiększa prawdopodobieństwo upadłości.



EBITDA (log)

Zdolność do generowania gotówki operacyjnej (zysk przed odsetkami i amortyzacją) jest kluczowym buforem bezpieczeństwa.

Różnice w architekturze modeli przekładają się na specyficzne akcenty w ocenie ryzyka:

Regresja Logistyczna

Silniej akcentuje wskaźniki dźwigni finansowej (Leverage Ratio) oraz płynności (aktywa/zobowiązania). Traktuje ryzyko w sposób liniowy i addytywny.

XGBoost

Przypisuje większą wagę relacjom strukturalnym, takim jak stosunek kapitału własnego do aktywów (Equity-to-Assets) oraz interakcjom nieliniowym, np. gwałtowny wzrost ryzyka po przekroczeniu pewnego progu zadłużenia.

Analiza Nieliniowości i Interakcji w Modelach


Zrozumienie, jak modele Regresji Logistycznej i XGBoost postrzegają nieliniowe zależności i interakcje między zmiennymi, jest kluczowe dla pełnej interpretacji ryzyka.

Analiza Nieliniowości i Punktów Zwrotnych (PDP & ICE)

Analiza krzywych zależności cząstkowych (Partial Dependence Plots - PDP) ujawniła fundamentalne różnice w postrzeganiu ryzyka przez modele.


1. Efekt Plateau (XGBoost)

W przypadku modelu drzewiastego zaobserwowano efekt nasycenia. Przykładowo, dla zmiennej **Kapitał Zapasowy**, ryzyko spada gwałtownie wraz z jego wzrostem, ale tylko do pewnego poziomu – dalsze gromadzenie kapitału nie przynosi już istotnej poprawy oceny ratingowej ("Plateau Effect").



2. Efekt Progowy (Threshold Effect)


XGBoost identyfikuje tzw. "punkty bólu" (turning points). Dla wskaźników zadłużenia, ryzyko jest stabilne do pewnego poziomu, po czym następuje skokowy wzrost PD. Regresja Logistyczna modeluje to jako stały, liniowy wzrost ryzyka, co może być nadmiernym uproszczeniem rzeczywistości gospodarczej.



Analiza Interakcji (2D Interaction Effects)

Badanie interakcji par zmiennych (2D PDP) potwierdziło, że ryzyko kredytowe nie jest sumą prostą czynników.

- Synergia Ryzyka:** W modelu XGBoost zaobserwowano na przykład, że jednoczesne wystąpienie niskiego **Kapitału Zapasowego** i wysokiego stosunku **Aktywów do Kapitału Własnego** skutkuje nieproporcjonalnie wyższym PD niż wynikałoby to z sumy tych ryzyk osobno.
- Różnice w Modelowaniu:** Wykresy dla Regresji Logistycznej przedstawiają płaszczyzny o równoległych warstwicach (brak interakcji), podczas gdy XGBoost tworzy skomplikowane powierzchnie z "kieszeniami ryzyka" (risk pockets).



Analiza Przypadków Granicznych: Interpretacje SHAP


Aby pogłębić zrozumienie zachowania modeli w praktyce, przeanalizowano dwa kluczowe przypadki: firm o najwyższym ryzyku niewypłacalności oraz firm znajdujących się w "szarej strefie", blisko progu decyzyjnego.

Przypadek 1: Max PD (Najwyższe Ryzyko)


Firmy z najwyższymi prawdopodobieństwami upadłości zostały poddana szczegółowej diagnozie. Wartości SHAP jednoznacznie wskazały na krytyczne czynniki ryzyka.

Głównymi czynnikami "pchającymi" wynik w górę były: **niski kapitał własny** oraz **ekstremalnie wysoki wskaźnik ogólnego zadłużenia**. Te dwa elementy zadecydowały o klasyfikacji firm jako wysoce ryzykowne.

Regresja Logistyczna



XGBoost




Przypadek 2: Obserwacja Graniczna (Borderline)


Ten przypadek dotyczy firm, której prawdopodobieństwo niewypłacalności jest bliskie progu odcięcia, co czyni je trudną do jednoznacznej klasyfikacji.

Wyjaśnienia SHAP są tu kluczowe dla analityka, ponieważ pokazują "walkę" czynników pozytywnych z negatywnymi. Zmienne obniżające ryzyko są równoważone przez te, które je zwiększają, co prowadzi do niepewnej predykcji i wymaga dogłębnej analizy kontekstowej.

Regresja Logistyczna



XGBoost



Kluczowe Cechy i Wnioski Biznesowe

Na podstawie kompleksowej analizy XAI zidentyfikowano 4 filary oceny ryzyka w modelu XGBoost:



Struktura Kapitałowa

Wysoki poziom kapitału zapasowego jest najsilniejszym stabilizatorem. Zależność wykazuje silne plateau.



Obsługa Długu

Ryzyko rośnie wykładniczo po przekroczeniu bezpiecznego wskaźnika lewarowania, co podkreśla nieliniową reakcję na dług.



Efektywność Operacyjna

Zdolność do generowania dodatkowych strumieni przychodów działa stymulująco na rating.



Płynność i Rentowność


Brak lub niski poziom EBITDA to natychmiastowy sygnał ostrzegawczy.

XGBoost zidentyfikował nieliniowe wzorce i interakcje, których model liniowy nie jest w stanie uchwycić, co uzasadnia jego ekonomiczny sens wdrożenia.


Wyniki Ilościowe i Interpretacja Rozbieżności Modeli

Analiza wykazała niską zgodność między modelami, co obrazują poniższe wyniki statystyczne:

- Dla wartości SHAP (Mean |SHAP|)
 - Korelacja rankingowa Spearmana: 0.3250
 - Istotność statystyczna (p-value): 1.48×10^{-3}
 - Wniosek: Modele nadają priorytet zupełnie innym atrybutom (**Niska Zgodność**).
- Dla Permutation Importance
 - Korelacja rankingowa Spearmana: 0.3855
 - Istotność statystyczna (p-value): 1.36×10^{-4}
 - Wniosek: Podobnie jak w przypadku SHAP, hierarchia ważności cech jest rozbieżna.



Rozrzut rankingów SHAP (LR vs XGB).



Rozrzut rankingów Permutation Importance (LR vs XGB).

Interpretacja Niskiej Korelacji

Uzyskane wyniki (korelacja < 0.4) należy interpretować jako sukces modelu Challenger:

1 Wartość dodana złożoności

Gdyby korelacja była wysoka (> 0.8), oznaczałoby to, że XGBoost nie nauczył się niczego nowego względem prostej Regresji Logistycznej. Niska korelacja dowodzi, że XGBoost zidentyfikował nieliniowe wzorce oraz interakcje, których model liniowy nie jest w stanie uchwycić. Uzasadnia to ekonomiczny sens wdrożenia bardziej skomplikowanego algorytmu.

2 Obsługa cech skorelowanych

Różnice w rankingach wynikają również z odmiennej mechaniki modeli:

- **Regresja Logistyczna:** W przypadku silnie skorelowanych zmiennych (np. różne warianty rentowności), model ma tendencję do "dzielenia" wagi między nie (rozmywanie ważności).
- **XGBoost:** Algorytm drzewiasty zazwyczaj wybiera jedną, najlepszą cechę z grupy skorelowanej do wykonania podziału (split), ignorując pozostałe. Prowadzi to do sytuacji, gdzie jedna cecha ma bardzo wysoką ważność, a jej bliski substytut zerową, co naturalnie obniża korelację rankingową względem modelu liniowego.

Konkluzja: XGBoost "patrzy" na dane w sposób fundamentalnie odmienny, wykorzystując strukturę nieliniową, co w połączeniu z lepszymi wynikami (AUC, Kalibracja) czyni go modelem bardziej wnikliwym, a nie tylko inną aproksymacją trendu liniowego.

Test na Danych Niewidzianych: Porównanie Metryk

Jako ostateczny sprawdzian odporności modeli, przeprowadzono ewaluację na specjalnie wydzielonym zbiorze walidacyjnym (N=300). Ten zbiór, nieużywany na żadnym wcześniejszym etapie, symuluje "wdrożenie produkcyjne" na całkowicie nowych danych, co pozwala ocenić stabilność i generalizację modeli w realistycznych warunkach.

Skalibrowana Regresja Logistyczna

Próg: 0.0640

Zbiór	ROC AUC	PR AUC	KS Stat	Recall	Brier Score
Train	0.7570	0.3553	0.3729	0.4034	0.1143
Test	0.7453	0.3714	0.4039	0.3718	0.1145
Validation	0.7441	0.3235	0.4044	0.2564	0.1157

Skalibrowany XGBoost

Próg: 0.0597

Zbiór	ROC AUC	PR AUC	KS Stat	Recall	Brier Score
Train	0.7615	0.3374	0.3924	0.5322	0.1138
Test	0.7606	0.3403	0.4182	0.4743	0.1144
Validation	0.7113	0.3161	0.3522	0.3590	0.1175

Wniosek: Analiza metryk na zbiorach treningowym, testowym i walidacyjnym wskazuje, że Regresja Logistyczna wykazuje większą stabilność, szczególnie w warunkach testowania na niewidzianych danych walidacyjnych. Choć XGBoost osiąga marginalnie lepsze wyniki na zbiorach Train i Test, jego spadek wydajności na zbiorze walidacyjnym jest bardziej widoczny, co sugeruje, że model liniowy jest bardziej odporny na zmienność danych w środowisku produkcyjnym.

System Ratingowy i Wsparcie Decyzji

Aby operacjonalizować wyniki modelu, opracowano system klasyfikacji klientów oparty na kolorach ryzyka (Risk Traffic Lights). System ten mapuje skalibrowane prawdopodobieństwo niewypłacalności (PD) na konkretne rekomendacje:

SAFE (Zielony)

PD < 80% prog. Klient bezpieczny, automatyczna akceptacja.

WARNING (Żółty)

80% prog. ≤ PD < próg. Obszar podwyższonego ryzyka, wymagana weryfikacja analityka.

HIGH RISK (Czerwony)

PD ≥ próg. Wysokie ryzyko niewypłacalności, rekomendowane odrzucenie.

Poniżej przedstawiono przykładową tabelę decyzyjną wygenerowaną przez model Regresji Logistycznej dla zbioru walidacyjnego. Wizualizacja pozwala szybko ocenić poziom ryzyka dla każdego przypadku.

	PD %	Rating	Status	Threshold	% over threshold
0	2.21%	A	SAFE	6.40%	-4.19%
1	8.44%	CCC	HIGH RISK	6.40%	2.04%
2	1.02%	AA	SAFE	6.40%	-5.38%
3	2.55%	A	SAFE	6.40%	-3.85%
4	9.05%	CCC	HIGH RISK	6.40%	2.65%
5	0.99%	AA	SAFE	6.40%	-5.41%
6	2.31%	A	SAFE	6.40%	-4.09%
7	6.09%	BB	WARNING	6.40%	-0.3%
8	2.27%	A	SAFE	6.40%	-4.12%
9	2.58%	A	SAFE	6.40%	-3.82%
10	2.34%	A	SAFE	6.40%	-4.06%
11	4.0%	BBB	SAFE	6.40%	-2.4%
12	7.98%	B	HIGH RISK	6.40%	1.58%
13	5.57%	BB	WARNING	6.40%	-0.83%
14	2.11%	A	SAFE	6.40%	-4.28%

Made with GAMMA

Dziękujemy!