

Raport Techniczny: Modelowanie Ryzyka Kredytowego i Predykcja Niewypłacalności

Maciej Andrzejewski, Krzysztof Osiński

Spis treści

1	Cel i Zakres Projektu	4
1.1	Definicja Problemu Biznesowego	4
1.2	Kluczowe Wymagania Techniczne	4
2	Wstęp i Zdefiniowanie Problemu Biznesowego	4
2.1	Kontekst Makroekonomiczny	4
2.2	Cel Projektu	4
2.3	Kluczowe Wymagania i Ograniczenia	5
2.4	Wartość Biznesowa	5
3	Dane i Strategia Walidacji	5
3.1	Charakterystyka Danych	5
3.2	Schemat Walidacji	5
4	Metodyka Modelowania i Przetwarzania Danych	6
4.1	Inżynieria Cech (Feature Engineering)	6
4.2	Specyfikacja Modeli	6
4.2.1	Model Interpretowalny (Benchmark)	6
4.2.2	Model Zaawansowany (Challenger)	6
5	Strategia Kalibracji i Oceny	6
5.1	Metryki Oceny	6
5.2	Kalibracja do 4% (Central Tendency)	6
6	Przygotowanie Danych i Analiza Eksploracyjna (EDA)	7
6.1	Jakość Danych i Czyszczenie (Data Quality)	7
6.2	Inżynieria Cech (Feature Engineering)	7
6.3	Pipeline Przetwarzania Danych	7
6.4	Obsługa Zmiennych Kategorycznych i WoE	8
7	Model Interpretowalny (Regresja Logistyczna)	9
7.1	Specyfikacja Algorytmu	9
7.2	Selekcja Zmiennych i Stabilność	9
7.3	Ocena Wyników (Ewaluacja)	9
8	Szczegółowa Analiza Eksploracyjna (EDA)	9
8.1	Rozkład Zmiennej Celu i Niezbalansowanie	9
8.2	Analiza Korelacji i Redukcja Współliniowości	10
8.3	Analiza Mocy Predykcyjnej (Information Value)	11
8.4	Analiza Wielowymiarowa i Separowalność Klas	11
8.5	Strategia Obsługi Wartości Odstających	12

8.6	Wnioski Biznesowe i Strategia Modelowania	12
9	Implementacja Procesu Modelowania	13
9.1	Strategia Podziału Danych	13
9.2	Zaawansowana Selekcja Cech (Advanced Feature Selection)	13
9.2.1	Wynik Selekcji	14
10	Budowa Modeli Predykcyjnych (Model Development)	14
10.1	Model Interpretowalny: Regresja Logistyczna	14
10.1.1	Konfiguracja Hiperparametrów	14
10.1.2	Wyniki Modelu Liniowego	14
10.2	Model Black-Box: XGBoost	15
10.2.1	Konfiguracja Hiperparametrów	15
10.2.2	Wyniki Modelu XGBoost	15
10.3	Podsumowanie Porównawcze (Benchmark vs Challenger)	16
11	Kalibracja Probabilistyczna i Decyzje Biznesowe	16
11.1	Diagnostyka Wstępna (Pre-Calibration)	16
11.2	Metodyka Kalibracji Hybrydowej	17
11.3	Wyniki Kalibracji (Post-Calibration)	17
11.4	Mapowanie PD na Klasy Ratingowe	17
11.4.1	Metodyka Tworzenia Skali	17
11.4.2	Definicja Progów Ratingowych (Rating Thresholds)	18
11.4.3	Charakterystyka Klas Ratingowych	18
12	Interpretowalność i Wyjaśnialność Modeli (XAI)	19
12.1	Optymalizacja Punktu Odcięcia (Threshold Tuning)	20
12.2	Ewaluacja Metryk i Stabilność Predykcji	20
12.3	Interpretowalność Wewnętrzna Regresji Logistycznej (Glass-box Approach)	21
12.3.1	Analiza Współczynników Beta	21
12.3.2	Selekcja Poprzez Regularyzację L1 (Lasso)	22
12.4	Analiza Współliniowości i Ważności Cech	22
12.4.1	Współliniowość (VIF)	22
12.4.2	Globalna Ważność Cech (Permutation & SHAP Importance)	23
12.4.3	Cechy Wspólne (Intersection)	24
12.4.4	Specyfika Modeli	25
12.5	Analiza Nieliniowości i Punktów Zwrotnych (PDP & ICE)	27
12.6	Analiza Interakcji (2D Interaction Effects)	29
12.7	Wyjaśnialność Lokalna (Case Studies)	30
12.7.1	Przypadek 1: Max PD (Najwyższe Ryzyko)	30
12.7.2	Przypadek 2: Obserwacja Graniczna (Borderline)	32
12.8	Równość i Stabilność Podgrup (Fairness Audit)	33
12.9	Kluczowe Cechy - Podsumowanie Biznesowe	34
12.10	Analiza Spójności Wyjaśnień Między Modelami	34
12.10.1	Wyniki Ilościowe	35
12.10.2	Interpretacja Niskiej Korelacji	35
12.11	Podsumowanie Wyjaśnialności	36
13	Ostateczna Walidacja i Wdrożenie (Final Validation)	36
13.1	Test na Danych Niewidzianych (Unseen Data)	36
13.2	System Ratingowy i Wsparcie Decyzji	36

14 Narzędzia Wdrożeniowe i Automatyzacja	37
14.1 Moduł "One-Click" do Oceny Nowych Danych	37
14.1.1 Instrukcja Użycia	38

1 Cel i Zakres Projektu

1.1 Definicja Problemu Biznesowego

Celem projektu jest zaprojektowanie systemu oceny ryzyka kredytowego w oparciu o historyczne dane finansowe. Kluczowym zadaniem jest predykcja zdarzenia ryzyka (flagi *default*) w ustalonym horyzoncie czasowym.

Wymagane jest dostarczenie dwóch komplementarnych rozwiązań:

1. **Model Interpretowalny:** Niezbędny do celów regulacyjnych i operacyjnych, gdzie kluczowa jest przejrzystość struktury decyzyjnej (np. karta punktowa).
2. **Model "Black-box":** Wykorzystujący zaawansowane algorytmy uczenia maszynowego w celu maksymalizacji siły dyskryminacyjnej, służący jako benchmark (challenger model).

1.2 Kluczowe Wymagania Techniczne

Zgodnie ze specyfikacją projektową, modele muszą spełniać rygorystyczne kryteria:

- **Kalibracja Probabilistyczna:** Obowiązkowe dostrojenie średniego przewidywanego PD do poziomu 4% (Calibration-in-the-large).
- **Wyjaśnialność (Explainability):** Zastosowanie metod model-agnostic (SHAP, LIME) do analizy modelu złożonego oraz porównanie ich spójności z modelem interpretowalnym.
- **Mapowanie na Ratingi:** Transformacja oszacowanego PD na klasy ratingowe z zachowaniem monotoniczności.

2 Wstęp i Zdefiniowanie Problemu Biznesowego

2.1 Kontekst Makroekonomiczny

Współczesne otoczenie gospodarcze stawia przed instytucjami finansowymi bezprecedensowe wyzwania. Wysoka inflacja wymusiła zaostrzenie polityki monetarnej (wzrost stóp procentowych), co bezpośrednio przekłada się na rosnące koszty obsługi długu i pogorszenie płynności finansowej przedsiębiorstw. W konsekwencji obserwuje się wzrost liczby upadłości oraz zjawisko zatorów płatniczych, co czyni precyzyjną ocenę ryzyka kredytowego (Credit Risk Assessment) kluczowym elementem strategii przetrwania instytucji finansowych.

2.2 Cel Projektu

Głównym celem projektu jest zaprojektowanie, budowa i walidacja zaawansowanego systemu ratingowego, służącego do estymacji Prawdopodobieństwa Niewypłacalności (PD - Probability of Default) dla polskich przedsiębiorstw niefinansowych w horyzoncie 12-miesięcznym.

Projekt realizuje strategię "Dual-Model Approach", dostarczając dwa komplementarne rozwiązania:

1. **Model Benchmarkowy (Interpretowalny):** Oparty na Regresji Logistycznej i technice Weight of Evidence (WoE). Jego priorytetem jest pełna transparentność decyzji oraz zgodność z rygorystycznymi wytycznymi regulatorów (KNF, EBA) dotyczącymi zarządzania ryzykiem modelu.
2. **Model Challenger (Black-Box):** Wykorzystujący algorytmy boostingowe (XGBoost) w celu maksymalizacji zdolności dyskryminacyjnej i wychwycenia nieliniowych zależności, które umykają modelom tradycyjnym.

2.3 Kluczowe Wymagania i Ograniczenia

System predykcyjny musi spełniać szereg zdefiniowanych kryteriów biznesowych i technicznych:

- **Kalibracja do Tendencji Centralnej:** Średnie przewidywane PD portfela musi wynosić 4%. Jest to wymóg narzucony przez politykę apetytu na ryzyko (Risk Appetite Statement) oraz konieczność spójności z długoterminowymi statystykami niewypłacalności.
- **Wyjaśnialność (Explainability):** Zastosowanie metod XAI (SHAP, PDP) jest obligatoryjne, aby "otworzyć czarną skrzynkę" modelu Challenger i zapewnić zrozumienie przyczyn odrzucenia wniosku kredytowego.
- **Minimalizacja NPL:** Model ma na celu wczesną identyfikację podmiotów zagrożonych, co pozwoli na redukcję portfela kredytów niepracujących (Non-Performing Loans).

2.4 Wartość Biznesowa

Wdrożenie opracowanego rozwiązania ma przynieść wymierne korzyści operacyjne:

- **Automatyzacja Decyzji:** Przyspieszenie procesów kredytowych poprzez automatyczną ścieżkę decyzyjną dla klientów o niskim ryzyku (Green Zone).
- **Optymalizacja Kapitałowa:** Precyzyjne oszacowanie PD pozwala na adekwatne tworzenie odpisów aktualizujących (provisions) oraz optymalizację wymogów kapitałowych.
- **Wsparcie Eksperckie:** Dostarczenie analitykom kredytowym narzędzi interpretacyjnych (wykresy wpływu cech), wspierających ocenę w przypadkach niejednoznacznych (Grey Zone).

3 Dane i Strategia Walidacji

3.1 Charakterystyka Danych

Analiza opiera się na zbiorze danych finansowych (`zbiór_2.csv`) zawierającym zmienne behawioralne, finansowe oraz makroekonomiczne, wśród nich głównie pozycje bilansu, pozycje Rachunku Zysków i Strat oraz wskaźniki finansowe. Zmienną celu (*target*) jest binarna flaga niewypłacalności/default ($Y \in \{0, 1\}$).

3.2 Schemat Walidacji

Aby uniknąć wycieku danych (data leakage) i zapewnić stabilność modelu zastosowano podział danych na zbiory:

- **Treningowy (Train):** Estymacja parametrów i tuning hiperparametrów.
- **Kalibracyjny (Cal):** Kalibracja modeli do średniej PD 4%.
- **Testowy (Test):** Ocena skuteczności modeli i analiza interpretowalności.
- **Walidacyjny (Val):** Ostateczna ocena stabilności metryk modeli.

4 Metodyka Modelowania i Przetwarzania Danych

4.1 Inżynieria Cech (Feature Engineering)

Proces przygotowania danych obejmuje następujące kroki:

1. **Jakość Danych:** Analiza braków danych (m.in. identyfikacja kolumn, dla których zera oznaczają braki) oraz detekcja anomalii.
2. **Binning i WoE:** Dla zmiennych kategorycznych wymuszono monotoniczność trendu *Weight of Evidence* (WoE), co zwiększa stabilność i interpretowalność.
3. **Selekcja Zmiennych:** Eliminacja zmiennych o wysokiej współliniowości (VIF) oraz niskiej mocy predykcyjnej (Information Value - IV).

4.2 Specyfikacja Modeli

4.2.1 Model Interpretowalny (Benchmark)

Jako interpretowalny model benchmarkowy zastosowano **Regresję Logistyczną**. Zalety: Bezpośrednia interpretacja logarytmu szans (log-odds) i łatwość wdrożenia w formie karty punktowej (Scorecard).

4.2.2 Model Zaawansowany (Challenger)

Jako model "black-box" zastosowano algorytm oparty na gradient boostingu (**XGBoost**). Strategia tuningu: Random/Grid Search w celu doboru hiperparametrów (learning rate, max depth, subsample) przy jednoczesnej kontroli overfittingu.

5 Strategia Kalibracji i Oceny

5.1 Metryki Oceny

Skuteczność modeli mierzona jest wielowymiarowo:

- **Klasyfikacja:** Accuracy, Precision, Recall, F1 Score.
- **Separacja i Dyskryminacja:** AUC-ROC, Gini Coefficient, KS-statistic.
- **Precyzja:** PR-AUC (ze względu na niezbalansowanie klas).
- **Kalibracja:** Brier Score, Expected Calibration Error (ECE).

5.2 Kalibracja do 4% (Central Tendency)

Bezpośrednie wyjścia z modeli mogą nie odzwierciedlać rzeczywistego prawdopodobieństwa niewypłacalności (szczególnie przy undersamplingu lub złożonych modelach drzewiastych). Naszym celem jest poprawne modelowanie rzeczywistości w jakiej funkcjonuje bank, stąd rodzi się konieczność kalibracji modeli. Zostanie zastosowana metoda **Platt Scaling**, a następnie korekta interceptu (calibration-in-the-large), aby spełnić warunek:

$$\mathbb{E}[\hat{P}_{calibrated}] \approx 4\% \quad (1)$$

6 Przygotowanie Danych i Analiza Eksploracyjna (EDA)

6.1 Jakość Danych i Czyszczenie (Data Quality)

Analizie poddano zbiór danych składający się z 3000 obserwacji oraz 220 zmiennych pierwotnych. Wstępny audyt jakości danych wykazał:

- **Duplikaty:** Nie stwierdzono występowania duplikatów w zbiorze.
- **Braki danych:** Dane finansowe są niekompletne, co jest naturalne (różne standardy raportowania). Zwykle usuwanie wierszy doprowadziłoby do utraty cennych informacji o specyficznych podmiotach, więc należy rozważyć inne strategie. Łączny odsetek braków danych w zbiorze wyniósł 3.16%. Z pozoru nie jest to wysoka wartość, zidentyfikowano jednak zmienne o krytycznym poziomie braków (powyżej 98%), takie jak `RP_przepływy_operacyjne` oraz `wsk_akt_generowania_got_2`, które zostały wykluczone z dalszych analiz.
- **Obsługa zer:** Zastosowano dedykowaną politykę traktowania wartości zerowych, które w zależności od kontekstu mogły zostać uznane za rzeczywistą wartość lub brak danych. Dla zmiennych bilansowych (np. `Aktywa`, `zobowi`) oraz wskaźników fiNaN"owych (np. `ROS`, `ROA`) wartość "0" została zamieniona na "NaN" (brak danych), aby uniknąć zafałszowania rozkładów, podczas gdy dla zmiennych typu `Zapasy` czy `Gotówka` zero pozostało wartością informatywną.


6.2 Inżynieria Cech (Feature Engineering)

W celu wydobycia nieliniowych zależności i zwiększenia mocy predykcyjnej modeli, zaimplementowano zaawansowany transformator cech finansowych (`FinancialFeatureEngineer`). Proces ten obejmował:

1. **Transformacje matematyczne:** Zastosowano logarytmizację (`log1p`) dla zmiennych o rozkładzie skośnym oraz pierwiastkowanie, aby ustabilizować wariancję.
2. **Wskaźniki finansowe:** Wygenerowano kluczowe wskaźniki rentowności i płynności, m.in.:
 - *Profit Margin* (Zysk netto / Przychody),
 - *Current Ratio* (Aktywa obrotowe / Zobowiązania krótkoterminowe),
 - *Rotacja zapasów* i *Rotacja należności*.
3. **Komponenty Modelu Altmana:** Utworzono zmienne aproksymujące składowe Z-Score, takie jak `working_capital_to_assets` czy `EBIT_to_assets`.
4. **Normalizacja czasem istnienia:** Zmienne wolumenowe (np. `Aktywa`) zostały znormalizowane przez liczbę dni istnienia firmy, co pozwala na lepsze porównanie podmiotów o różnym stażu.

6.3 Pipeline Przetwarzania Danych

Opracowano kompleksowy potok przetwarzania (`dataFullTransformer`), składający się z następujących kroków sekwencyjnych:



Rysunek 1: Wizualizacja potoku ETL zaimplementowanego w klasie dataFullTransformer.

1. **Polityka wobec braków danych:** Zamiana wartości Inf i 0 (dla odpowiednich kolumn) na wartości NaN.
2. **Usuwanie zmiennych stałych:** Eliminacja kolumn o zerowej wariancji (DropConstantFeatures).
3. **Capping (Winsoryzacja):** Ograniczenie wpływu obserwacji odstających poprzez przycięcie górnego ogona rozkładu do 95. percentyla (OutliersClipper).
4. **Selekcja niska wariancja:** Usunięcie cech o wariancji poniżej progu 0.5.
5. **Imputacja:** Uzupełnienie braków danych metodą iteracyjną (IterativeImputer - MICE) z inicjalizacją medianą, co pozwala zachować korelacje między zmiennymi.
6. **Standaryzacja:** Skalowanie zmiennych do średniej 0 i odchylenia standardowego 1.
7. **Eliminacja korelacji:** Usunięcie zmiennych silnie skorelowanych powyżej progu 0.7, aby zredukować współliniowość.

6.4 Obsługa Zmiennych Kategorycznych i WoE

Zmienne symboliczne, takie jak kody PKD (pkdKod) oraz forma własności (formaWlasnosci_Symbol), poddano wstępnemu grupowaniu eksperkiemu.

- **PKD:** Kody pogrupowano w sektory makroekonomiczne (np. "Energetyka i budownictwo", "Handel hurtowy", "Rolnictwo").
- **Forma własności:** Zredukowano do głównych kategorii (np. "Sektor prywatny krajowy", "Sektor publiczny").

Następnie zastosowano kodowanie **Weight of Evidence (WoE)**, co pozwoliło na wprowadzenie nieliniowych zależności kategorycznych do modelu liniowego przy zachowaniu interpretowalności.

7 Model Interpretowalny (Regresja Logistyczna)

7.1 Specyfikacja Algorytmu

Jako model benchmarkowy (interpretowalny) wybrano **Regresję Logistyczną**. Decyzja ta podyktowana jest wymogami regulacyjnymi dotyczącymi przejrzystości procesu decyzyjnego.

Kluczowym elementem konstrukcji modelu jest wymuszenie **jednokierunkowości wpływu zmiennych** na ryzyko. Zastosowano autorski transformator `SignCorrelationTransformer`, który automatycznie odwraca znak zmiennych ujemnie skorelowanych z targetem. Zabieg ten gwarantuje, że wyższe wartości zmiennych w modelu finalnym zawsze przekładają się na ten sam kierunek zmiany prawdopodobieństwa (zgodność z intuicją biznesową), co jest fundamentem budowy kart punktowych (scorecards).

7.2 Selekcja Zmiennych i Stabilność

Proces selekcji zmiennych do modelu logistycznego oparto na:

1. **Analizie IV (Information Value)**: Wstępna selekcja cech o najwyższej mocy dyskryminacyjnej.
2. **Analizie VIF (Variance Inflation Factor)**: Eliminacja zmiennych współliniowych poprzez `DropCorrelatedFeatures` (próg 0.7).
3. **Weryfikacji znaków**: Sprawdzenie zgodności znaku współczynnika regresji z ekonomiczną intuicją (np. wyższa płynność = niższe ryzyko) zapewnione przez `SignCorrelationTransformer`.

7.3 Ocena Wyników (Ewaluacja)


Model poddano ocenie na zbiorze testowym. Zgodnie z funkcją `evaluate_model_side_by_side`, weryfikowano następujące metryki:

- **ROC AUC i PR AUC**: Miary zdolności dyskryminacyjnej modelu.
- **Statystyka KS (Kolmogorov-Smirnov)**: Ocena maksymalnej separacji dystrybuant "dobrych" i "złych" klientów.
- **Brier Score i Log Loss**: Miary oceniające kalibrację prawdopodobieństw.

8 Szczegółowa Analiza Eksploracyjna (EDA)

8.1 Rozkład Zmiennej Celu i Niezbalansowanie

Analiza struktury zmiennej objaśnianej (`default`) wykazała istotne niezbalansowanie klas. W badanym zbiorze udział firm, które ogłosiły upadłość, wynosi **12.97%**. Mimo że jest to odsetek wyższy niż w typowych portfelach bankowych (gdzie $PD \approx 1-3\%$), nadal wskazuje na konieczność stosowania metryk odpornych na niezbalansowanie, takich jak ROC-AUC czy Precision-Recall, zamiast skupiania się na *Accuracy*.




Rysunek 2: Histogram udziału klas w zbiorze treningowym (Default rate: 12.97%).

8.2 Analiza Korelacji i Redukcja Współliniowości

Wstępna analiza macierzy korelacji wykazała silne powiązania między wskaźnikami finansowymi (np. wskaźniki rentowności oparte na zbliżonych licznikach). Nadmiarowość informacji utrudnia interpretację wpływu poszczególnych cech i może prowadzić do niestabilności modeli liniowych.


- Zidentyfikowano liczne pary zmiennych o współczynniku korelacji Pearsona $r > 0.7$.
- W celu uniknięcia niestabilności modelu logistycznego (problem multikolinearności), zastosowano procedurę iteracyjnej eliminacji jednej ze zmiennych z pary skorelowanej powyżej progu 0.8.



Rysunek 3: Macierz korelacji po usunięciu wysoko skorelowanych cech.

8.3 Analiza Mocy Predykcyjnej (Information Value)

W celu selekcji zmiennych do modelu interpretowalnego przeprowadzono analizę **Information Value (IV)**. Pozwoliła ona na ranking cech pod kątem siły rozdzielczej (zdolności do separacji klas Good/Bad). Widać, że wiele cech ma spory potencjał predykcyjny.



Rysunek 4: Wykres najważniejszych zmiennych według Information Value (IV).


8.4 Analiza Wielowymiarowa i Separowalność Klas

Aby ocenić złożoność problemu klasyfikacyjnego, przeprowadzono redukcję wymiarowości przy użyciu metod **PCA** (Principal Component Analysis) oraz **t-SNE**.

Wnioski z wizualizacji 2D:

- **Brak separacji:** Klasy default (1) i non-default (0) silnie na siebie zachodzą w przestrzeni głównych składowych, nie widać separacji klas.
- **Złożona struktura:** Pierwsze dwa komponenty wyjaśniają jedynie ok. 20% wariancji, co oznacza, że prawdopodobnie informacja zawarta w danych jest rozproszona i bardziej złożona.

Powyższa obserwacja prognozuje konieczność użycia większej ilości cech w modelowaniu i stanowi argument za przetestowaniem modeli nieliniowych (takich jak XGBoost), gdyż w danych mogą występować złożone zależności, których prosta regresja logistyczna może nie uchwycić.



Rysunek 5: Wizualizacja PCA.

8.5 Strategia Obsługi Wartości Odstających

Potwierdzono występowanie ekstremalnych wartości wskaźników (tzw. "grube ogony" generowane np. w wyniku dzielenia przez bliski zero kapitał własny). Wdrożono ostateczną politykę **Winso-ryzacji (Clipping)**:

- Dolny próg odcięcia: 3. percentyl (Q3).
- Górny próg odcięcia: 97. percentyl (Q97).

Podejście to (zawężone względem pierwotnych testów) pozwala zachować rzeczywistą zmienność danych finansowych, eliminując jedynie błędy danych lub skrajne anomalie.

8.6 Wnioski Biznesowe i Strategia Modelowania

- **Złożoność problemu:** Separacja klas nie jest liniowa. Decyduje kombinacja wielu słabszych sygnałów, a nie jeden "złoty wskaźnik".
- **Rating jako Prawdopodobieństwo:** Wyjście modelu powinno być ciągłe (prawdopodobieństwo defaultu - PD), co pozwoli na segmentację firm na grupy ryzyka (klasy ratingowe).
- **Wybór Algorytmów:**
 - Gradient Boosting (XGBoost/LightGBM): Rekomendowane jako główne modele (odporność na braki, korelacje, wychwycenie nieliniowych zależności).
 - Regresja Logistyczna (z regularyzacją): Jako baseline dla porównania wyników i wyjaśnialności.

9 Implementacja Procesu Modelowania

9.1 Strategia Podziału Danych

Ze względu na ograniczoną liczebność próby (3000 obserwacji) oraz wymóg precyzyjnej kalibracji modelu, zastosowano złożony schemat podziału danych. Zamiast standardowego podziału Train/Test, wydzielono cztery niezależne podzbiory, co pozwala na uniknięcie wycieku informacji między etapami treningu, tuningu, kalibracji i ostatecznej oceny.

Zastosowano podział warstwowy względem zmiennej celu `default`, aby zachować stały odsetek bankrutów ($\approx 12\%$) w każdej próbce.

Tabela poniżej prezentuje finalną strukturę podziału:

Tabela 1: Struktura podziału zbioru danych

Podzbiór	Udział (%)	Liczba Obserwacji	Przeznaczenie
Treningowy (Train)	60%	1800	Trenowanie i tuning modeli
Kalibracyjny (Cal)	10%	300	Kalibracja
Testowy (Test)	20%	600	Testowanie performance'u
Walidacyjny (Val)	10%	300	Ostateczna ocena

Wydzielenie osobnego zbioru kalibracyjnego jest kluczowe dla spełnienia wymogu biznesowego dotyczącego zgodności średniego PD z tendencją centralną (4%), gdyż kalibracja na zbiorze treningowym prowadziłaby do nadmiernego dopasowania (overfitting).

9.2 Zaawansowana Selekcja Cech (Advanced Feature Selection)

W celu redukcji wymiarowości i eliminacji szumu, wdrożono hybrydowy mechanizm selekcji cech. Podejście to łączy metody filtrowe, wbudowane oraz wrapperowe, co zwiększa stabilność wybranego zestawu zmiennych.

Proces selekcji przebiegał w następujących krokach:

1. Filtry Wstępne:

- Usunięcie zmiennych o zerowej wariancji (stałych).
- Eliminacja zmiennych silnie skorelowanych ($r > 0.7$) w ramach pipeline'u przetwarzania (`DropCorrelatedFeatures`).

2. Ranking Metodami Wiodącymi: Dla każdej z poniższych metod wybrano N najlepszych cech:

- **Korelacja Pearsona:** Liniowa siła związku z targetem.
- **Mutual Information:** Nieliniowa zależność między cechą a zmienną celu.
- **Recursive Feature Elimination (RFE):** Iteracyjne usuwanie najsłabszych cech przy użyciu Regresji Logistycznej jako estymatora bazowego.
- **Feature Importance (Random Forest):** Ważność cech oparta na przyroście czystości węzłów (Gini impurity) w modelu lasu losowego.

3. Konsensus (Agregacja): Ostateczny zbiór cech stanowi sumę mnogościową wyników powyższych metod. Takie podejście minimalizuje ryzyko odrzucenia istotnej zmiennej, która mogłaby być niedoceniona przez pojedynczy algorytm.

9.2.1 Wynik Selekcji

W rezultacie procesu z początkowej puli zmiennych wyselekcjonowano finalnie 93 zmienne. Zbiór ten (`selected_features.pkl`) zawiera zarówno surowe wskaźniki finansowe, jak i zmienne przetworzone inżyniersko (np. `-log_Aktywa`, `wsk_rotacja_rz_aktywow_trwalych`).

Istotnym elementem jest obecność zmiennych ze znakiem ujemnym (np. `-log_Kapital_zapasowy`), co wynika z zastosowania transformacji `SignCorrelationTransformer` wymuszającej dodatnią korelację z ryzykiem (wyższa wartość cechy = wyższe ryzyko) dla potrzeb interpretowalności.

10 Budowa Modeli Predykcyjnych (Model Development)

W oparciu o wyselekcjonowane 93 cechy, wytrenowano dwa modele o odmiennej charakterystyce - regresję liniową oraz XGBoost. Na tym etapie analizowano wyniki surowe (przed kalibracją probabilistyczną), skupiając się na zdolności dyskryminacyjnej.

10.1 Model Interpretowalny: Regresja Logistyczna

Jako model bazowy (Benchmark) zastosowano Regresję Logistyczną z regularyzacją L2. Wybór ten podyktowany był koniecznością eliminacji mniej istotnych cech (feature selection wbudowany w model) oraz łatwością interpretacji.

10.1.1 Konfiguracja Hiperparametrów


Kluczowe parametry modelu dobrane w procesie eksperymentalnym:

- `penalty='l2'`: Wymuszenie rzadkości (sparsity) wektora współczynników, co dodatkowo redukuje szum.
- `C=0.0005`: Bardzo silna regularyzacja (odwrotność parametru λ) zapobiegająca przeuczeniu.
- `class_weight='balanced'`: Automatyczne doważenie klas rzadszych (bankrutów), co jest krytyczne przy Default Rate $\approx 13\%$.
- `solver='saga'`.

10.1.2 Wyniki Modelu Liniowego

Model wykazał wysoką stabilność działania, z minimalnym spadkiem jakości między zbiorem treningowym a testowym.

- **ROC AUC (Test):** 0.745
- **Gini (Test):** 0.49 (obliczone jako $2 \cdot AUC - 1$)
- **Recall (Test):** 65% – Model skutecznie wyłapuje dużą część bankrutów.
- **Precision (Test):** 23% – Niska precyzja wynika z agresywnego doważenia klas (duża liczba False Positives), co zostanie skorygowane na etapie doboru punktu odcięcia (cutoff).



Rysunek 6: Macierz pomyłek dla Regresji Logistycznej (zbiór treningowy i testowy).

10.2 Model Black-Box: XGBoost

Jako model wiodący (Challenger) wykorzystano algorytm *Extreme Gradient Boosting*. Jego celem jest wychwycenie nieliniowych interakcji między zmiennymi finansowymi, których nie obejmuje model liniowy.

10.2.1 Konfiguracja Hiperparametrów


Aby zapobiec przeuczeniu (overfitting) na relatywnie małym zbiorze (1800 obs. w treningu), zastosowano konserwatywne ustawienia ("płytkie drzewa"):

- `n_estimators=444`: Liczba drzew decyzyjnych.
- `max_depth=5`: Ograniczenie głębokości drzewa, kluczowe dla generalizacji.
- `learning_rate=0.000637`: Tempo uczenia (shrinkage).
- `scale_pos_weight`: Ręczne doważenie klasy pozytywnej (w przybliżeniu stosunek non-default/default), co pełni analogiczną funkcję do `class_weight='balanced'`.
- `reg_alpha=23.73`, `reg_lambda=27.04`: Dodatkowa regularyzacja L1/L2 funkcji straty.

10.2.2 Wyniki Modelu XGBoost

XGBoost osiągnął porównywalne wyniki do modelu logistycznego.

- **ROC AUC (Test):** 0.761.
- **Recall (Test):** 68%.



Rysunek 7: Macierz pomyłek dla XGBoosta (zbiór treningowy i testowy)

10.3 Podsumowanie Porównawcze (Benchmark vs Challenger)

Poniższa tabela zestawia kluczowe metryki efektywności obu modeli na zbiorze testowym (Out-of-Time).

Tabela 2: Porównanie skuteczności modeli (Zbiór Testowy, próg decyzyjny 0.5)

Model	ROC AUC	Precision (klasa 1)	Recall (klasa 1)	F1-Score
Regresja Logistyczna	0.745	0.24	0.69	0.35
XGBoost (Challenger)	0.761	0.23	0.65	0.34

Wniosek: Model XGBoost oferuje porównywalną jakość predykcji do modelu liniowego. Jednakże, surowe prawdopodobieństwa z obu modeli (szczególnie przy zastosowaniu wag klas) nie są skalibrowane - średnie przewidywane ryzyko jest znacznie wyższe niż rzeczywiste 4%. Wymaga to przeprowadzenia procesu kalibracji w kolejnym etapie.

11 Kalibracja Probabilistyczna i Decyzje Biznesowe

Celem tego etapu było przekształcenie surowych wyników modeli (score) w rzetelne prawdopodobieństwo niewypłacalności (PD), spełniające wymóg tendencji centralnej portfela na poziomie 4%.

11.1 Diagnostyka Wstępna (Pre-Calibration)

Modele trenowane na danych niebalansowanych z użyciem wag klas (`class_weight='balanced'` dla LR oraz `scale_pos_weight` dla XGB) generowały prawdopodobieństwa nieskalibrowane, znacząco przeszacowane względem rzeczywistości.

Analiza metryk na zbiorze testowym wykazała krytyczne odchylenia:

- **Expected Calibration Error (ECE):** Wynosił aż **0.3315** dla Regresji Logistycznej i **0.3598** dla XGBoost. Oznacza to, że średnio predykcje myliły się o ponad 30 punktów procentowych względem frakcji rzeczywistych bankructw.

- **Brier Score:** Wynosił odpowiednio 0.2108 (LR) i 0.2382 (XGB), co przy niskim a priori ryzyka (default rate $\approx 12\%$) świadczyło o słabej jakości kalibracji.
- **Średnie PD:** Surowe modele zwracały średnie prawdopodobieństwo bliskie 50% (efekt balansowania klas), co jest wartością nieakceptowalną biznesowo przy celu 4%.

11.2 Metodyka Kalibracji Hybrydowej

W celu naprawy krzywej wiarygodności zastosowano dwuetapowy proces kalibracji na wydzielonym zbiorze kalibracyjnym ($N = 300$):

1. **Korekta Kształtu (Platt Scaling):** Wykorzystano metodę Sigmoid (*CalibratedClassifierCV*), która dopasowała logistyczną funkcję mapującą surowe wyniki (logits) na prawdopodobieństwa.
2. **Calibration-in-the-large (Target Shifting):** Ponieważ sam Platt Scaling nie gwarantował idealnego trafienia w cel 4%, zastosowano analityczne przesunięcie interceptu. Skorygowane prawdopodobieństwo P_{cal} wyznaczono wzorem:

$$P_{cal} = \sigma(\text{logit}(P_{platt}) - \text{logit}(\bar{P}_{platt}) + \text{logit}(0.04)) \quad (2)$$

gdzie σ to funkcja sigmoidalna, a $\bar{P}_{platt}$ to średnie PD po pierwszym etapie kalibracji. Operacja ta przesuwa rozkład predykcji tak, aby jego średnia wynosiła dokładnie 4%, nie zmieniając rankingu klientów (zachowanie AUC).

11.3 Wyniki Kalibracji (Post-Calibration)

Zastosowana metoda przyniosła radykalną poprawę jakości predykcji. Błąd kalibracji został znacząco zredukowany.

Tabela 3: Porównanie metryk kalibracji na zbiorze testowym

Model	Przed Kalibracją		Po Kalibracji (4%)	
	ECE	Brier Score	ECE	Brier Score
Regresja Logistyczna	0.3315	0.2108	0.0914	0.1145
XGBoost	0.3598	0.2382	0.0901	0.1144

Ponieważ w danych dostępne były tylko historyczne flagi 0 i 1, a nie prawdopodobieństwa defaultów, nie jesteśmy w stanie dokładnie ocenić jakości kalibracji do 4% PD - fizycznie nie ma dla niej punktu odniesienia w danych.

11.4 Mapowanie PD na Klasy Ratingowe

Następnym etapem jest transformacja ciągłego, skalibrowanego prawdopodobieństwa niewypłacalności (PD) na dyskretną skalę ratingową (Master Scale). Proces ten pozwala na grupowanie podmiotów o zbliżonym profilu ryzyka, co ułatwia raportowanie i ustalanie limitów kredytowych.

11.4.1 Metodyka Tworzenia Skali

Zastosowano podejście oparte na dyskretyzacji PD, definiując klasy ratingowe (np. od A do C) w taki sposób, aby spełnić warunek monotoniczności: średnie PD w każdej kolejnej (gorszej) klasie ratingowej musi być wyższe niż w klasie poprzedniej.

11.4.2 Definicja Progów Ratingowych (Rating Thresholds)

W celu obiektywizacji procesu nadawania ratingów, progi odcięcia (bins) dla poszczególnych klas zostały wyznaczone przy użyciu algorytmu klasteryzacji **K-Means**. Metoda ta pozwoliła na znalezienie naturalnych skupień ryzyka w rozkładzie PD, minimalizując wariancję wewnątrz każdej klasy ratingowej.

Poniższe tabele prezentują zdefiniowane przedziały prawdopodobieństwa niewypłacalności (PD Range) dla 9-stopniowej skali ratingowej (od AAA do C) dla obu modeli.

Tabela 4: Tabela Ratingowa: Skalibrowana Regresja Logistyczna

Rating	Opis Ryzyka	Dolny Próg PD	Górny Próg PD
AAA	Ryzyko znikome	0.00%	1.70%
AA	Ryzyko bardzo niskie	1.70%	2.95%
A	Ryzyko niskie	2.95%	4.37%
BBB	Ryzyko umiarkowane	4.37%	6.17%
BB	Ryzyko podwyższone	6.17%	8.25%
B	Ryzyko wysokie	8.25%	10.98%
CCC	Ryzyko bardzo wysokie	10.98%	21.49%
CC	Ryzyko ekstremalne	21.49%	34.81%
C	Niewypłacalność / Default	34.81%	100.00%


Tabela 5: Tabela Ratingowa: Skalibrowany XGBoost

Rating	Opis Ryzyka	Dolny Próg PD	Górny Próg PD
AAA	Ryzyko znikome	0.00%	1.37%
AA	Ryzyko bardzo niskie	1.37%	2.61%
A	Ryzyko niskie	2.61%	4.04%
BBB	Ryzyko umiarkowane	4.04%	5.41%
BB	Ryzyko podwyższone	5.41%	7.11%
B	Ryzyko wysokie	7.11%	9.31%
CCC	Ryzyko bardzo wysokie	9.31%	10.94%
CC	Ryzyko ekstremalne	10.94%	12.76%
C	Niewypłacalność / Default	12.76%	100.00%


Wniosek Analityczny: Porównanie tabel ujawnia istotną różnicę w "ostrości" oceny. Model XGBoost znacznie szybciej degraduje ratingi – klasa C (najgorsza) zaczyna się już od PD = 12.76%, podczas gdy w Regresji Logistycznej dopiero od 34.81%. Oznacza to, że **XGBoost jest bardziej restrykcyjny** wobec podmiotów o podwyższonym ryzyku, wcześniej klasyfikując je jako toksyczne, co jest pożądane z punktu widzenia minimalizacji strat (Loss Given Default).

11.4.3 Charakterystyka Klas Ratingowych

Poniższe histogramy prezentują "profil ryzyka" wygenerowanych klas.



Rysunek 8: Struktura ryzyka w klasach ratingowych: Model Regresji Logistycznej.



Rysunek 9: Struktura ryzyka w klasach ratingowych: Model XGBoost.

12 Interpretowalność i Wyjaśnialność Modeli (XAI)

Zgodnie z wymogami regulacyjnymi oraz potrzebą zrozumienia mechanizmów decyzyjnych, przeprowadzono pogłębioną analizę wyjaśnialności (*eXplainable AI*) dla obu modeli. Wykorzystano metody model-agnostic, w szczególności wartości SHAP (SHapley Additive exPlanations) oraz analizę zależności cząstkowych (PDP/ICE).

Uwaga1: Z powodu ogromnej liczby zmiennych niemożliwe jest przeprowadzenie analizy każdej cechy z osobna. Dlatego też w poniższej sekcji przedstawione zostaną najważniejsze predyktory oraz tendencje w danych, które mają decydujący wpływ na przewidywania modeli.

Uwaga2: Ponieważ kalibracja modeli wpływa jedynie na przesunięcie p-stw defaultu, w większości przypadków badania interpretowalności i wyjaśnialności posługiwać się będziemy modelami nieskalibrowanymi (wyniki będą tożsame, a dla bazowych modeli istnieją bardziej optymalne metody analizy (np. *LinearShap*).

12.1 Optymalizacja Punktu Odcięcia (Threshold Tuning)

Przed przystąpieniem do interpretacji, wyznaczono optymalne progi decyzyjne, maksymalizujące miarę F_β (gdzie $\beta = 1$, kładąc równy nacisk na precyzję i czułość). Dla modelu skalibrowanego wyznaczono progi operacyjne na poziomie 6.40% dla Regresji Logistycznej oraz 5.97% dla XGBoosta. Oznacza to, że każda firma z prawdopodobieństwem defaultu powyżej tego progu jest klasyfikowana jako ryzykowna.

12.2 Ewaluacja Metryk i Stabilność Predykcji

Przed przystąpieniem do interpretacji, zweryfikowano stabilność modeli poprzez analizę metryk na zbiorach treningowym i testowym. Oba modele wykazały wysoką zbieżność metryk (AUC, F1) między zbiorem treningowym a testowym, co świadczy o braku istotnego przeuczenia (overfittingu) i stabilności reguł decyzyjnych.

=== Metryki Train vs Test ===

	precision_train	precision_test	recall_train	recall_test	f1-score_train	f1-score_test	support_train	support_test
0	0.910726	0.904110	0.904914	0.885057	0.907810	0.894482	1567.0	522.0
1	0.386831	0.325843	0.403433	0.371795	0.394958	0.347305	233.0	78.0

=== Metryki Globalne Probabilistyczne ===

	Train	Test
Metric		
ROC AUC	0.7570	0.7453
PR AUC	0.3553	0.3714
KS Stat	0.3729	0.4039
Log Loss	0.4095	0.4640
Brier Score	0.1143	0.1145
Accuracy	0.8400	0.8183

Rysunek 10: Porównanie metryk Modelu Regresji Logistycznej

=== Metryki Train vs Test ===								
	precision_train	precision_test	recall_train	recall_test	f1-score_train	f1-score_test	support_train	support_test
0	0.921695	0.911447	0.818762	0.808429	0.867185	0.856853	1567.0	522.0
1	0.303922	0.270073	0.532189	0.474359	0.386895	0.344186	233.0	78.0

=== Metryki Globalne Probabilistyczne ===			
	Train	Test	
Metric			
ROC AUC	0.7615	0.7606	
PR AUC	0.3374	0.3403	
KS Stat	0.3924	0.4182	
Log Loss	0.4080	0.4078	
Brier Score	0.1138	0.1144	
Accuracy	0.7817	0.7650	

Rysunek 11: Porównanie metryk Modelu XGBoost

12.3 Interpretowalność Wewnętrzna Regresji Logistycznej (Glass-box Approach)

Przed zastosowaniem metod model-agnostic (SHAP), dokonano bezpośredniej analizy struktury modelu Regresji Logistycznej. W przeciwieństwie do modeli zespołowych, regresja oferuje jawną formułę matematyczną łączącą dane wejściowe z ryzykiem, co pozwala na analizę *ceteris paribus* (przy innych warunkach niezmiennych).

12.3.1 Analiza Współczynników Beta

Dzięki zastosowaniu standaryzacji zmiennych (`StandardScaler`) w pipeline przetwarzania, surowe wartości współczynników regresji β_i stają się bezpośrednio porównywalne i odzwierciedlają siłę wpływu danej cechy na logarytm szans (log-odds) bankructwa.

Gdzie β_i interpretujemy następująco:

- **Kierunek wpływu:** Znak współczynnika (dodatni/ujemny) determinuje, czy wzrost wartości cechy zwiększa, czy zmniejsza ryzyko. W naszym modelu, dzięki zastosowaniu *Sign-CorrelationTransformer*, zadbane o zgodność znaków z intuicją ekonomiczną (np. spadek płynności zawsze podnosi ryzyko).
- **Siła wpływu:** Ponieważ zmienne mają odchylenie standardowe równe 1, wartość bezwzględna $|\beta_i|$ jest bezpośrednią miarą ważności cechy (Feature Importance). Wzrost cechy o 1 odchylenie standardowe zmienia log-odds o wartość β_i .

	Zmienna	β	OR	$ \beta $
0	numeric_pipeline_log_wsk_zadluzenia	0.0771	1.0801	0.0771
1	numeric_pipeline_-log_Kapital_zapasowy	0.0562	1.0578	0.0562
2	numeric_pipeline_wsk_ogolnego_zadluzenia_pozyczki_squared	0.0439	1.0448	0.0439
3	numeric_pipeline_log_wsk_koszty_przychody	0.0429	1.0438	0.0429
4	numeric_pipeline_-log_wsk_pokrycia_odsetek_zyskiem	0.0413	1.0422	0.0413
5	numeric_pipeline_wsk_zadluzenia_pozyczki_dlugie_sqrt	0.0395	1.0403	0.0395
6	numeric_pipeline_log_wsk_efekt_dzwigni_fin_1	0.0389	1.0396	0.0389
7	numeric_pipeline_-log_pozostale_przychody_oper	0.0372	1.0379	0.0372
8	numeric_pipeline_-log_Naleznosci_dostaw_uslug_12m_powiazane	0.0370	1.0377	0.0370
9	numeric_pipeline_-log_wsk_ebitda_koszty_odsetkowe_3	0.0351	1.0358	0.0351
10	numeric_pipeline_log_wsk_rotacja_rz_aktywow_trwalych	0.0346	1.0352	0.0346

Rysunek 12: Współczynniki β_i w modelu regresji logistycznej

12.3.2 Selekcja Poprzez Regularyzację L1 (Lasso)

Wewnętrzna interpretowalność modelu została dodatkowo wzmocniona przez zastosowanie regularyzacji L2 podczas treningu. Mechanizm ten wymusił wyzerowanie współczynników dla cech nieistotnych lub nadmiarowych.

12.4 Analiza Współliniowości i Ważności Cech

12.4.1 Współliniowość (VIF)

Dla modelu Regresji Logistycznej, wrażliwego na multikolinearność, przeprowadzono analizę czynnika inflacji wariancji (VIF). Zmienne o $VIF > 5$ zostały poddane weryfikacji. W modelu XGBoost (drzewiastym) współliniowość jest naturalnie obsługiwana przez mechanizm doboru podziałów (split points), jednak silna korelacja może rozmywać ważność cech (Feature Importance).


	Feature	VIF
27	numeric_pipeline_-log_Inwestycje_krotkoterminowe	11.481833
66	numeric_pipeline_wsk_efekt_dzwigni_fin_1_sqrt	11.328063
49	numeric_pipeline_-wsk_ebitda_3_sqrt	9.643134
19	numeric_pipeline_-log_Aktywa	9.492312
48	numeric_pipeline_-log_wsk_marza_ebit	9.474317
...	...	...
47	numeric_pipeline_-wsk_zysk_ebitda_1	1.146534
24	numeric_pipeline_wsk_ogolnego_zadluzenia_2	1.130193
53	numeric_pipeline_wsk_marza_brutto_1	1.127672
69	symbols_pipeline_formaWlasnosci_Symbol	1.113307
61	numeric_pipeline_wsk_rent_kapitalu	1.060625

Rysunek 13: Analiza VIF - Variance Inflation Factor


12.4.2 Globalna Ważność Cech (Permutation & SHAP Importance)

Zastosowano dwie komplementarne metody oceny ważności:

1. **Permutation Importance:** Mierzy spadek jakości modelu (np. AUC) po losowym przemieszaniu wartości danej cechy.




Rysunek 14: Permutation Importance dla Regresji Logistycznej




Rysunek 15: Permutation Importance dla XGBoosta

Nietrudno zauważyć, że część cech (jak np. logarytm Kapitału zapasowego) jest ważna dla obu modeli, jak również istnieją zestawy cech unikalne do każdego z modelu.

2. **SHAP Feature Importance:** Średnia wartość bezwzględna Shapley values ($mean(|SHAP|)$), określająca globalny wpływ na wynik predykcji.



Rysunek 16: SHAP Feature Importance dla Regresji Logistycznej



Rysunek 17: SHAP Feature Importance dla XGBoosta

Pod względem ważności cech występuje tu analogiczna sytuacja, jak w przypadku Permutation Importance.


12.4.3 Cechy Wspólne (Intersection)

Mimo różnic w architekturze, oba modele zgodnie wskazały grupę fundamentalnych wskaźników finansowych determinujących ryzyko:


- **Kapitał Zapasowy (log):** Wysoki poziom kapitału zapasowego jest najsilniejszym stabilizatorem (obniża ryzyko).
- **Wskaźnik Zadłużenia Ogólnego (log):** Wzrost zadłużenia wprost proporcjonalnie zwiększa prawdopodobieństwo upadłości.
- **EBITDA (log):** Zdolność do generowania gotówki operacyjnej (zysk przed odsetkami i amortyzacją) jest kluczowym buforem bezpieczeństwa.

12.4.4 Specyfika Modeli

- **Regresja Logistyczna:** Silniej akcentuje wskaźniki dźwigni finansowej (Leverage Ratio) oraz płynności (aktywa/zobowiązania). Traktuje ryzyko w sposób liniowy i addytywny.
- **XGBoost:** Przypisuje większą wagę relacjom strukturalnym, takim jak stosunek kapitału własnego do aktywów (**Equity-to-Assets**) oraz interakcjom nieliniowym, np. gwałtowny wzrost ryzyka po przekroczeniu pewnego progu zadłużenia.



Rysunek 18: SHAP beeswarm dla Regresji Logistycznej




Rysunek 19: SHAP beeswarm dla XGBoost


12.5 Analiza Nieliniowości i Punktów Zwrotnych (PDP & ICE)

Analiza krzywych zależności cząstkowych (Partial Dependence Plots - PDP) ujawniła fundamentalne różnice w postrzeganiu ryzyka przez modele.

1. **Efekt Plateau (XGBoost):** W przypadku modelu drzewiastego zaobserwowano efekt nasycenia. Przykładowo, dla zmiennej *Kapitał Zapasowy*, ryzyko spada gwałtownie wraz z jego wzrostem, ale tylko do pewnego poziomu – dalsze gromadzenie kapitału nie przynosi już istotnej poprawy oceny ratingowej ("Plateau Effect").
2. **Efekt Progowy (Threshold Effect):** XGBoost identyfikuje tzw. "punkty bólu" (turning points). Dla wskaźników zadłużenia, ryzyko jest stabilne do pewnego poziomu, po czym następuje skokowy wzrost PD. Regresja Logistyczna modeluje to jako stały, liniowy wzrost ryzyka, co może być nadmiernym uproszczeniem rzeczywistości gospodarczej.



Rysunek 20: Porównanie krzywych PDP: Liniowa zależność w Regresji vs Nieliniowa (schodkowa) w XGBoost.




Rysunek 21: Porównanie scentrowanych krzywych ICE: Liniowa zależność w Regresji vs Nieliniowa (schodkowa) w XGBoost.

12.6 Analiza Interakcji (2D Interaction Effects)

Badanie interakcji par zmiennych (2D PDP) potwierdziło, że ryzyko kredytowe nie jest sumą prostą czynników.

- **Synergia Ryzyka:** W modelu XGBoost zaobserwowano na przykład, że jednocześnie wystąpienie niskiego Kapitału zapasowego i wysokiego stosunku Aktywów do Kapitału Własnego skutkuje nieproporcjonalnie wyższym PD niż wynikałoby to z sumy tych ryzyk osobno.
- Wykresy dla Regresji Logistycznej przedstawiają płaszczyzny o równoległych warstwach (brak interakcji), podczas gdy XGBoost tworzy skomplikowane powierzchnie z "kieszeniami ryzyka" (risk pockets).



Rysunek 22: Porównanie 2D-PDP dla Kapitału zapasowego oraz stosunku Aktywów do Kapitału własnego


12.7 Wyjaśnialność Lokalna (Case Studies)

W celu walidacji predykcji na poziomie pojedynczego klienta, przeanalizowano wybrane przypadki graniczne i skrajne, używając metod SHAP Waterfall oraz LIME.


12.7.1 Przypadek 1: Max PD (Najwyższe Ryzyko)

Analizie poddano firmę o najwyższym wyliczonym prawdopodobieństwie upadłości.

- **Diagnoza SHAP:** Głównymi czynnikami "pychającymi" wynik w górę były: ujemny kapitał własny oraz ekstremalnie wysoki wskaźnik ogólnego zadłużenia.




Rysunek 23: Dekompozycja predykcji przy pomocy SHAP dla firmy o największym PD dla Regresji Liniowej



Rysunek 24: Dekompozycja predykcji przy pomocy SHAP dla firmy o największym PD dla XGBoosta

- **LIME:** Potwierdził odczyty SHAP, wskazując te same cechy jako lokalne determinanty decyzji w otoczeniu tej obserwacji.




Rysunek 25: Dekompozycja predykcji przy pomocy LIME dla firmy o największym PD (XGBoost)


12.7.2 Przypadek 2: Obserwacja Graniczna (Borderline)

Firma znajdująca się blisko progu odcięcia (Gray Zone).

- Wyjaśnienia SHAP są tu kluczowe dla analityka. Pokazują one "walkę" czynników pozytywnych z negatywnymi.



Rysunek 26: Dekompozycja oceny ryzyka dla przykładowego klienta z pogranicza akceptacji dla Modelu Regresji Logistycznej.



Rysunek 27: Dekompozycja oceny ryzyka dla przykładowego klienta z pogranicza akceptacji dla Modelu XGBoost (niekoniecznie tego samego, co dla Regresji Logistycznej).

12.8 Równość i Stabilność Podgrup (Fairness Audit)

Przeprowadzono audyt równości (Fairness) modelu względem segmentów kwartylowych. Analiza metryk (AUC, Brier Score) w podgrupach wykazała:

- Brak drastycznych różnic w jakości predykcji między głównymi sektorami.

- Stabilność wyjaśnień: Najważniejsze cechy pozostają podobne w różnych podgrupach, co świadczy o tym, że model nie dyskryminuje specyficznych segmentów w oparciu o artefakty danych.

--- Audyt dla cechy: numeric_pipeline__log_wsk_zadluzenia ---

	Segment	Liczebność	AUC	Brier	Średnie PD	Rzeczywisty DR	Różnica vs Global AUC
0	Q1 (Niskie)	150	0.675945	0.189666	0.416396	0.093333	-0.069388
1	Q4 (Wysokie)	150	0.706051	0.253269	0.532294	0.246667	-0.039282
3	Q3	150	0.714206	0.201422	0.439329	0.086667	-0.031128
2	Q2	150	0.789916	0.198948	0.441500	0.093333	0.044582

--- Audyt dla cechy: numeric_pipeline__wsk_efekt_dzwigni_fin_1 ---

	Segment	Liczebność	AUC	Brier	Średnie PD	Rzeczywisty DR	Różnica vs Global AUC
2	Q1 (Niskie)	150	0.632000	0.252830	0.504374	0.166667	-0.113334
1	Q4 (Wysokie)	150	0.730202	0.236333	0.505232	0.180000	-0.015132
0	Q2	150	0.775407	0.180137	0.411685	0.086667	0.030074
3	Q3	150	0.851207	0.174005	0.408228	0.086667	0.105874

Rysunek 28: Przykładowy audyt dwóch cech w obrębie segmentów kwartylowych dla Regresji Logistycznej

12.9 Kluczowe Cechy - Podsumowanie Biznesowe

Na podstawie kompleksowej analizy XAI, zidentyfikowano 4 filary oceny ryzyka w modelu XGBoost:

1. **Struktura Kapitałowa** ($-\log_Kapital_zapasowy$): Najsilniejszy predyktor. Firmy akumulujące zyski w kapitale zapasowym są znacznie bezpieczniejsze. Zależność wykazuje silne plateau.
2. **Obsługa Długu** ($\log_wsk_zadluzenia$): Nieliniowa reakcja na dług. Ryzyko rośnie wykładniczo po przekroczeniu bezpiecznego wskaźnika lewarowania.
3. **Efektywność Operacyjna** ($-\log_pozostale_przychody$): Zdolność do generowania dodatkowych strumieni przychodów działa stymulująco na rating.
4. **Płynność i Rentowność** ($-\log_wsk_ebitda$): EBITDA pozostaje "królem cash flow". Jej brak lub niski poziom jest natychmiastowym sygnałem ostrzegawczym (czerwona flaga).


12.10 Analiza Spójności Wyjaśnień Między Modelami

W celu weryfikacji, czy model złożony (XGBoost) faktycznie wnosi nową jakość analityczną, czy jedynie replikuje logikę modelu liniowego, przeprowadzono badanie korelacji rankingowej ważności cech. Porównano rankingi 93 cech wygenerowane przez oba modele przy użyciu dwóch metod: SHAP oraz Permutation Importance. Do oceny zgodności wykorzystano współczynnik korelacji rang Spearmana (ρ).


12.10.1 Wyniki Ilościowe

Analiza wykazała niską zgodność między modelami, co obrazują poniższe wyniki statystyczne:

- **Dla wartości SHAP (Mean |SHAP|):**
 - Korelacja rankingowa Spearmana: **0.3250**
 - Istotność statystyczna (p-value): 1.48×10^{-3}
 - **Wniosek:** Modele nadają priorytet zupełnie innym atrybutom (Niska Zgodność).
- **Dla Permutation Importance:**
 - Korelacja rankingowa Spearmana: **0.3855**
 - Istotność statystyczna (p-value): 1.36×10^{-4}
 - **Wniosek:** Podobnie jak w przypadku SHAP, hierarchia ważności cech jest rozbieżna.



Rysunek 29: Rozrzut rankingów SHAP (LR vs XGB).



Rysunek 30: Rozrzut rankingów Permutation Importance (LR vs XGB).

12.10.2 Interpretacja Niskiej Korelacji

Uzyskane wyniki (korelacja < 0.4) należy interpretować jako **sukces modelu Challenger**.

1. **Wartość dodana złożoności:** Gdyby korelacja była wysoka (> 0.8), oznaczałoby to, że XGBoost nie nauczył się niczego nowego względem prostej Regresji Logistycznej. Niska korelacja dowodzi, że XGBoost zidentyfikował **nieliniowe wzorce oraz interakcje**, których model liniowy nie jest w stanie uchwycić. Uzasadnia to ekonomiczny sens wdrożenia bardziej skomplikowanego algorytmu.
2. **Obsługa cech skorelowanych:** Różnice w rankingach (szczególnie niższy wynik dla SHAP niż PI w niektórych aspektach) wynikają również z odmiennej mechaniki modeli:
 - **Regresja Logistyczna:** W przypadku silnie skorelowanych zmiennych (np. różne warianty rentowności), model ma tendencję do "dzielenia" wagi między nie (rozmywanie ważności).

- **XGBoost:** Algorytm drzewiasty zazwyczaj wybiera jedną, najlepszą cechę z grupy skorelowanej do wykonania podziału (split), ignorując pozostałe. Prowadzi to do sytuacji, gdzie jedna cecha ma bardzo wysoką wagę, a jej bliski substytut zerową, co naturalnie obniża korelację rankingową względem modelu liniowego.

Konkluzja: XGBoost "patrzy" na dane w sposób fundamentalnie odmienny, wykorzystując strukturę nieliniową, co w połączeniu z lepszymi wynikami (AUC, Kalibracja) czyni go modelem bardziej wnikliwym, a nie tylko inną aproksymacją trendu liniowego.

12.11 Podsumowanie Wyjaśnialności

Analiza XAI dostarcza kluczowego wniosku biznesowego: **XGBoost lepiej odzwierciedla złożoną naturę bankructwa**, identyfikując nieliniowe strefy zagrożenia, które umykają modelom liniowym. Jednocześnie, dzięki narzędziom takim jak SHAP, model ten przestaje być "czarną skrzynką" i może być z powodzeniem stosowany w procesach decyzyjnych, oferując precyzyjne uzasadnienie dla każdego odrzuconego wniosku kredytowego.

13 Ostateczna Walidacja i Wdrożenie (Final Validation)

13.1 Test na Danych Niewidzianych (Unseen Data)

Jako ostateczny sprawdzian odporności modeli, przeprowadzono ewaluację na wydzielonym zbiorze walidacyjnym ($N = 300$), który nie był używany na żadnym wcześniejszym etapie (Train/Test/Cal). Jest to symulacja "wdrożenia produkcyjnego" na całkowicie nowych danych.

Wyniki walidacji wskazują na spadek skuteczności względem zbioru testowego, co jest zjawiskiem naturalnym przy tak małej liczebności próby, ale ujawnia też różnice w stabilności modeli:

Tabela 6: Wyniki na zbiorze walidacyjnym ($N=300$, Unseen Data)

Model	ROC AUC	Brier Score	Accuracy	F1-Score (klasa 1)
Regresja Logistyczna (LR)	0.7441	0.1157	83.00%	0.28
XGBoost (XGB)	0.7113	0.1175	78.67%	0.30

Wniosek: Na małej i trudnej próbce walidacyjnej, **Regresja Logistyczna okazała się stabilniejsza** (AUC 0.74 vs 0.71). Sugeruje to, że choć XGBoost ma wyższy potencjał na dużych zbiorach, model liniowy jest bezpieczniejszą "kotwicą" w warunkach dużej zmienności danych.

13.2 System Ratingowy i Wsparcie Decyzji

W celu operacjonalizacji wyników modelu, opracowano system klasyfikacji klientów oparty na kolorach ryzyka (Risk Traffic Lights). System ten mapuje skalibrowane PD na konkretne rekomendacje:

- **SAFE (Zielony):** $PD < 80\%$ progu. Klient bezpieczny, automatyczna akceptacja.
- **WARNING (Żółty):** $80\% \text{ progu} \leq PD < \text{próg}$. Obszar podwyższonego ryzyka, wymagana weryfikacja analityka.
- **HIGH RISK (Czerwony):** $PD \geq \text{próg}$. Wysokie ryzyko niewypłacalności, rekomendowane odrzucenie.

Poniżej przedstawiono przykładową tabelę decyzyjną wygenerowaną przez model Regresji Logistycznej dla zbioru walidacyjnego:

	PD %	Rating	Status	Threshold	% over threshold
0	2.21%	A	SAFE	6.40%	-4.19%
1	8.44%	CCC	HIGH RISK	6.40%	2.04%
2	1.02%	AA	SAFE	6.40%	-5.38%
3	2.55%	A	SAFE	6.40%	-3.85%
4	9.05%	CCC	HIGH RISK	6.40%	2.65%
5	0.99%	AA	SAFE	6.40%	-5.41%
6	2.31%	A	SAFE	6.40%	-4.09%
7	6.09%	BB	WARNING	6.40%	-0.3%
8	2.27%	A	SAFE	6.40%	-4.12%
9	2.58%	A	SAFE	6.40%	-3.82%
10	2.34%	A	SAFE	6.40%	-4.06%
11	4.0%	BBB	SAFE	6.40%	-2.4%
12	7.98%	B	HIGH RISK	6.40%	1.58%
13	5.57%	BB	WARNING	6.40%	-0.83%
14	2.11%	A	SAFE	6.40%	-4.28%

Rysunek 31: Tabela ratingowa z wizualizacją poziomu ryzyka dla Regresji Liniowej (Case Study z pliku walidacyjnego).

14 Narzędzia Wdrożeniowe i Automatyzacja

14.1 Moduł "One-Click" do Oceny Nowych Danych

W celu zapewnienia natychmiastowej operacyjności modelu (Time-to-Market) oraz łatwości jego adaptacji na nowych portfelach danych, przygotowano dedykowane narzędzie wdrożeniowe: *ONE-CLICK-TEST.ipynb*.

Narzędzie to stanowi w pełni zautomatyzowany potok wnioskowania (*Inference Pipeline*), który integruje wszystkie etapy procesu modelowania:

1. **Ładowanie Artefaktów:** Skrypt automatycznie wczytuje zserializowane obiekty modelu (*CalibratedXGBoost.pkl*), transformatora danych (*dataPreprocessor.pkl*) oraz listy cech (*selected_features.pkl*), gwarantując pełną spójność z wersją treningową.
2. **Przetwarzanie:** Surowe dane wejściowe poddawane są identycznym przekształceniom (inżynieria cech, imputacja, WoE), co eliminuje ryzyko błędów implementacyjnych.
3. **Scoring i Raportowanie:** Dla każdej obserwacji wyliczane jest skalibrowane PD, a następnie przypisywana jest kategoria ratingowa (Green/Yellow/Red).

14.1.1 Instrukcja Użycia

Rozwiązanie zostało zaprojektowane w formule *Low-Code*. Aby dokonać oceny ryzyka na własnym zbiorze danych, użytkownik musi jedynie zdefiniować ścieżkę do pliku wejściowego w zmiennej konfiguracyjnej.

Wynikiem działania skryptu jest gotowy raport (plik `scored_data.csv`), zawierający decyzje kredytowe gotowe do wykorzystania biznesowego.